

EigenSkill-Q 阶段交付：可验证量化策略旁路

日期：2026-06-04

结论

当前最稳的研究主线是：

Verifiable Policy Bypass for Sensitivity-Rate-Distortion Guided Mixed-Precision LLM Quantization

不要把项目写成已经完成的 edge LLM、swarm LLM 或真正 eigen-routing。短周期 成果应聚焦在 “量化策略技能 + 可验证 policy kernel + 数学/强化学习扩展”。

已完成

- 1. 新增 C++ policy evaluator:inference_cpp/src/quant_policy_bypass.cpp
- 2. 扩展 Windows/MSVC build 脚本: inference_cpp/build-msvc.ps1 -Target quant-policy
- 3. 验证 eval/test:

split	rows	policy_fields_exact	decision_exact	parse_error	throughput
eval	400	1.000000	1.000000	0.000000	8261
test	400	1.000000	1.000000	0.000000	6924

- 4. Python strict oracle 已验证:

split	rows	exact_json	decision_exact	parse_error
eval	400	1.000000	1.000000	0.000000
test	400	1.000000	1.000000	0.000000

- 5. 已写交付文件:

outputs/EigenSkill-Q-Cpp-Policy-Bypass-Report.md
outputs/paper_delivery_2026-06-04/EigenSkill-Q_CCF-A_Draft.md
outputs/paper_delivery_2026-06-04/导师速览.md
outputs/paper_delivery_2026-06-04/authorization-and-channel-audit.md

数学主线

把量化策略写成约束优化：

$$\begin{aligned} &\text{minimize} \quad \sum_l D_l(W_l, A_l, Q_l) + \alpha C_l(b_l, R_l, o_l, r_l, k_l) \\ &\text{subject to} \quad \sum_l M_l(b_l, k_l) \leq B \\ &\quad \quad \quad \sum_l T_l(b_l, R_l, r_l, k_l) \leq T \\ &\quad \quad \quad \text{Risk}_l(o_l, b_l, k_l) \leq \epsilon_l \end{aligned}$$

在线版本写成 constrained contextual bandit：

$$\begin{aligned} &\text{maximize} \quad E[\text{Reward}(x_t, a_t)] \\ &\text{subject to} \quad E[\text{Memory}(x_t, a_t)] \leq B \\ &\quad \quad \quad E[\text{Latency}(x_t, a_t)] \leq T \\ &\quad \quad \quad P(\text{QualityDrop}(x_t, a_t) > \delta) \leq \epsilon \end{aligned}$$

候选 CCF-A 路线

避开 NeurIPS / MLSys 后，建议按证据强度选择：

- ICML：数学、rate-distortion、bandit/RL 足够强时；
- IJCAI / AAAI：AI policy learning + 真实量化实验；
- ACL：可靠工具执行 / structured generation / LLM serving；
- AI / TPAMI / JMLR：期刊路线，需要完整理论和更强实验。

TNNLS 在 CCF AI 官方页列为 B，不建议作为“CCF-A”主推，除非学校另有名单。

不能声称

- 不能声称已完成真正 Transformer $O(d)$ eigen-routing；
- 不能声称已超过 GPTQ/AWQ/SmoothQuant/QuaRot/SpinQuant/QuIP/AQLM；
- 不能声称已有真实 edge/NPU/ARM 能耗或延迟结果；
- 不能把 swarm/acoustic/physical assembly 写成已实现贡献。

下一步

1. 真实模型：Qwen2.5-0.5B/1.5B、Llama-3.2-1B/3B、SmolLM2-1.7B。
2. 真实量化：RTN、GPTQ、AWQ、SmoothQuant、QuaRot/SpinQuant。
3. 策略实验：heuristic、deterministic C++、learned bandit/RL。
4. 指标：PPL、task accuracy、memory、latency、policy overhead、router failure。

参考链接

- CCF AI 推荐目录：https://www.ccf.org.cn/Academic_Evaluation/AI/
- GPTQ：<https://arxiv.org/abs/2210.17323>

- AWQ: <https://arxiv.org/abs/2306.00978>
- SmoothQuant: <https://arxiv.org/abs/2211.10438>
- QuaRot: <https://arxiv.org/abs/2404.00456>
- SpinQuant: <https://arxiv.org/abs/2405.16406>
- QuIP#: <https://arxiv.org/abs/2402.04396>
- OmniQuant: <https://arxiv.org/abs/2308.13137>
- AQLM: <https://arxiv.org/abs/2401.06118>
- KIVI: <https://arxiv.org/abs/2402.02750>
- KVQuant: <https://arxiv.org/abs/2401.18079>