

EigenSkill-Q 导师速览

日期：2026-06-04

一句话定位

EigenSkill-Q 当前最稳的论文主线不是“端侧蜂群大模型”或“已证明的 Eigen-Routing”，而是：

面向混合精度 LLM 量化的可验证策略旁路：

把低熵、可审计、强数值规则的量化策略从 LLM token 生成中剥离，交给 Python/C++ policy kernel 执行。

这个方向更适合数学、机器学习、强化学习和量化方向的论文叙事。

当前已经完成的实证结果

1. 无泄漏量化策略数据集

数据集：data_eval/eigenskill_quant_v1

包含五类 quantization-policy skills：

outlier_detect
bit_allocate
rotation_select
residual_patch
kv_policy

规模：

train: 1200
eval: 400
test: 400

审计结果：

train/eval/test exact-row overlap = 0
train/eval/test input overlap = 0

这比早期 v2 routing split 强很多。早期 v2 存在严重 overlap，只能当工程 PoC，不能当泛化实验。

2. Python 严格 oracle

Python deterministic evaluator 在 eval/test 上达到：

split	rows	exact_json	decision_exact	parse_error
eval	400	1.000000	1.000000	0.000000
test	400	1.000000	1.000000	0.000000

这里的 exact_json 是严格 JSON 对齐，包括 risk、score 等辅助数值字段。

3. C++ policy kernel

新增 C++ 程序：

inference_cpp/src/quant_policy_bypass.cpp

编译：

powershell -ExecutionPolicy Bypass -File .\inference_cpp\build-msvc.ps1 -Target quant-policy

结果：

split	rows	policy_fields_exact	decision_exact	parse_error	throughput
eval	400	1.000000	1.000000	0.000000	8261 rows/s
test	400	1.000000	1.000000	0.000000	6924 rows/s

C++ 版本重点验证“关键策略字段”是否完全一致，不冒充严格 JSON oracle。

4. 小模型 LoRA 负结果

SmolLM2-360M 的短周期 LoRA smoke test：

json_valid: 35%
 schema_ok: 0%
 exact_json: 0%
 decision_exact: 0%

这个负结果反而支持论文动机：确定性数值策略不应该完全依赖小模型生成。

推荐论文主线

建议标题：

EigenSkill-Q: Verifiable Policy Bypass for
 Sensitivity-Rate-Distortion Guided Mixed-Precision LLM Quantization

核心假设：

LLM 适合做 semantic routing 和解释;
 低熵、强数值约束、可验证的量化策略适合交给 policy kernel;
 policy kernel 可以是确定性规则、表驱动 C++、或经过约束训练的 bandit/RL policy。

数学主线

量化策略可写成约束优化:

$$\begin{aligned} &\text{minimize} \quad \sum_l D_l(W_l, A_l, Q_l) + \alpha C_l(b_l, R_l, o_l, r_l, k_l) \\ &\text{subject to} \quad \sum_l M_l(b_l, k_l) \leq B \\ &\quad \quad \quad \sum_l T_l(b_l, R_l, r_l, k_l) \leq T \\ &\quad \quad \quad \text{Risk}_l(o_l, b_l, k_l) \leq \epsilon_l \end{aligned}$$

其中:

- b_l : bit width / format;
- R_l : rotation / preconditioner;
- o_l : outlier protection;
- r_l : residual correction rank;
- k_l : KV-cache policy;
- D_l : Hessian/Fisher/activation-MSE 加权 distortion;
- M_l/T_l : memory/latency;
- Risk_l : outlier 和可靠性风险。

在线策略可进一步写成 constrained contextual bandit:

$$\begin{aligned} &\text{maximize} \quad E[\text{Reward}(x_t, a_t)] \\ &\text{subject to} \quad E[\text{Memory}(x_t, a_t)] \leq B \\ &\quad \quad \quad E[\text{Latency}(x_t, a_t)] \leq T \\ &\quad \quad \quad P(\text{QualityDrop}(x_t, a_t) > \delta) \leq \epsilon \end{aligned}$$

这会把项目从“工程 if-else”提升为“可学习、可约束、可验证的量化控制层”。

适合投的方向

用户要求避开 NeurIPS / MLSys。更现实的 CCF-A 候选:

方向	候选	需要补强
机器学习/优化	ICML	数学形式、rate-distortion、bandit/RL 实验要强
人工智能	IJCAI / AAAI	策略学习 + 量化实验 + 可靠工具执行
NLP/LLM serving	ACL	把 policy bypass 写成可靠工具调用/结构化执行
期刊	AI / TPAMI / JMLR	需要完整理论、强 baseline、长实验周期

严格说明: TNNLS 很强, 但 CCF AI 官方页列为 B 类, 不建议在“CCF-A”包装里主推, 除非学校另外按中科院分区或本校名单认可。

目前不能声称的内容

当前不能写成已经完成：

- 真正 Transformer 层的 $O(d)$ eigen-routing;
- 穿过 LayerNorm / SwiGLU / residual nonlinear dynamics 的不变子空间证明;
- 超过 GPTQ/AWQ/SmoothQuant/QuaRot/SpinQuant/QuIP/AQLM 的量化效果;
- 真实 edge board / ARM / NPU latency 和 energy;
- 声学通信、物理蜂群、跨介质系统实现。

这些可以保留为 future work 或远景，不应放进主贡献。

下一阶段必须补的实验

1. 用 Qwen2.5-0.5B/1.5B 或 Llama-3.2-1B/3B 做真实量化。
2. 计算 calibration statistics: activation MSE、outlier score、Hessian/Fisher proxy、KV sensitivity。
3. 对比 uniform/RTN、GPTQ、AWQ、SmoothQuant、QuaRot/SpinQuant。
4. 做 policy ablation:
 - 无 policy;
 - heuristic policy;
 - C++ deterministic policy;
 - learned bandit/RL policy。
5. 报告 PPL、task accuracy、memory、latency、policy overhead。
6. 如果还要写 edge，必须上真实硬件再谈 latency/energy。

当前交付文件

outputs/EigenSkill-Q-Cpp-Policy-Bypass-Report.md
outputs/paper_delivery_2026-06-04/EigenSkill-Q_CCF-A_Draft.md
outputs/paper_delivery_2026-06-04/导师速览.md

这些文件可以先给导师看，但应明确：这是短周期 research draft，真正 CCF-A 投稿还需要真实模型量化实验和 baseline。